Japhet ALLAH-N'DIGUIM

Élève Ingénieur — Data Engineering

+212 777 757 825 • Fès, Maroc • allahndiguimj@gmail.com • linkedin.com/in/japhet-allah-n-diguim-764878320 • github.com/Mbaitedero

PROFIL

Lead Data & BI chez SmartAra depuis 2026, et étudiant ingénieur en 5e année Data Science & IA, spécialisé en ingénierie des données. Expérience concrète en architecture Lakehouse (Databricks, Delta Lake, Unity Catalog), streaming (Kafka, Spark Structured Streaming), transformation (dbt) et orchestration de pipelines (Apache Airflow). Rigoureux, autonome et orienté production.

COMPÉTENCES TECHNIQUES

Data Engineering	Databricks (PySpark, Delta Lake, Unity Catalog), Apache Airflow, Apache Spark (Structured Streaming), Kafka, dbt, Talend, Hadoop, ETL/ELT
Bases de données	PostgreSQL, MySQL, SQL Server, MongoDB
MLOps & Déploiement	MLflow, Docker/Docker Compose, Astro CLI, FastAPI
Qualité de données	Great Expectations, contrôles d'intégrité référentielle, tests automatisés (pytest)
Outils & Dev	Git/GitHub, Power BI, Linux, CI/CD (GitHub Actions)

EXPÉRIENCE PROFESSIONNELLE

Stagiaire Data / IA — ABISOFT *Juillet – Août 2026*

Pipeline Data & BI bancaire — Reporting réglementaire et détection de fraude (PFA) — année universitaire 2025 – 2026

- Architecture medallion (Bronze/Silver/Gold) sur Databricks : ingestion brute de 7 sources, nettoyage et feature engineering avancé (fenêtres glissantes), modélisation en constellation (3 faits, 3 dimensions).
- Orchestration de bout en bout (génération → ingestion → transformation → ML → scoring) via un DAG Apache Airflow de 13 tâches, déployé avec Astro CLI/Docker.
- Industrialisation MLOps : API FastAPI + interface Dash conteneurisées (Docker Compose), supervision Prometheus/Grafana, tests automatisés (pytest, Ruff) et CI/CD (GitHub Actions).
- Contrôles de qualité de données à chaque couche (unicité des clés, intégrité référentielle, volumétrie) pour garantir la fiabilité du pipeline.

Stagiaire Data Analyst / Data Science — ENSA Fès, Département Génie Électrique, Fès *Juillet – Août 2025*

- Collecte et structuration de 200+ profils d'artisans de la Médina via web scraping (BeautifulSoup / Selenium).
- Nettoyage et normalisation des données collectées (textes, catégories de métiers, localisation) en vue de l'analyse.
- Segmentation non supervisée par clustering KMeans (Silhouette Score 0,67) pour identifier des profils homogènes d'artisans.
- Restitution des résultats pour orienter les campagnes de promotion touristique locale.

PROJETS ACADÉMIQUES ET PERSONNELS

Olist Data Lakehouse Pipeline — Kafka, Spark Streaming, Delta Lake, dbt, Airflow • GitHub

- Pipeline end-to-end sur le dataset e-commerce brésilien Olist : producers Kafka → Spark Structured Streaming (Bronze/Silver) → Delta Lake (MinIO, compatible S3) → modélisation dbt (Gold) → orchestration Airflow.
- Contrôles de qualité des données (Great Expectations) et conteneurisation complète de la stack (Docker Compose).
- Modèles dbt orientés analytique : RFM client, performance de livraison, analyse produits et vendeurs.

Gestion Système Universitaire — MySQL, MongoDB, SQL Server, Talend, SSAS/SSRS • GitHub

- Data Warehouse multidimensionnel (schéma en étoile, 7 dimensions dont 2 en SCD Type 2) alimenté par 7 jobs ETL Talend depuis MySQL.
- Modélisation NoSQL complémentaire (MongoDB, 4 collections dénormalisées, 10 pipelines d'agrégation) ; restitution via cube OLAP SSAS et rapports SSRS.
- Projet réalisé dans le cadre de la certification Data Engineer ForceN Sénégal.

Data Warehouse E-commerce — PostgreSQL 16, Talend Open Studio

- Entrepôt de données en étoile (DIM_CLIENT, DIM_PRODUIT, DIM_CALENDRIER, FAIT_VENTE) sous PostgreSQL 16.
- Pipeline ETL Talend (ODS → Data Warehouse) : 4 jobs, lookups, tMap, gestion des Slowly Changing Dimensions, chargement de 17 000+ clients et 3 700+ produits.

Video Games Analytics — Python, PySpark, DuckDB, Elasticsearch, FastAPI • GitHub

- Pipeline idempotent de bout en bout (16 593 titres) : ingestion, nettoyage, feature engineering, stockage columnaire Parquet.
- Double moteur analytique DuckDB (OLAP in-process) + PySpark (détection d'outliers), indexation Elasticsearch et API REST FastAPI testée.

FORMATION

Cycle Ingénieur — Data Science & Intelligence Artificielle, ENSA de Fès 2024 – 2027

Classes Préparatoires Intégrées (CPI), ENSA de Fès 2022 – 2024

LANGUES

Français (courant) • Anglais (lecture & documentation technique) • Ngambaye (langue maternelle)

CENTRES D'INTÉRÊT

Intelligence artificielle et veille technologique • Entrepreneuriat numérique • Organisation de webinaires techniques • Projets personnels sur GitHub • Langues et cultures